

Contextualização do Problema

O Enterprise Challenge 2025 da FIAP começou com o Kick-off da TOTVS, empresa parceira deste ano, no qual nos foi apresentado um desafio de *clusterização* de clientes da empresa parceira. Para que pudéssemos realizar nossa proposta de solução, nos foram fornecidos diversos arquivos .csv, indo desde dados gerais de clientes, até dados de telemetria do uso de produtos da empresa.

CD_CLIENTE	DS_PROD	DS_LIN_REC	CIDADE	DS_CNAE	DS_SEGMENTO	DS_SUBSEGMENTO	FAT_FAIXA	MARCA_TOTVS	MODAL_COMERC	PAIS	PERIODICIDADE	SITUACAO_CONTRATO	UF	VL_TOTAL_CONTRATO	DT_ASSINATURA_CONTRATO	
0	99958	SMS FULL TOTVS TRAD	SMS TOTVS SERIE T	JOINVILLE	PESSOA FISICA (SEM CNAE)	SERVICOS	PROVEDOR SERVICOS	Faixa 09 - De 300 M ate 500 M	CROSS - TRADICIONAL	MODALIDADE TRADICIONAL	105	00 - Mensal	GRATUITO	SC	1633817,36581438	2016-04-07
1	T00053	SMS COLAB NEO 2500 DOC	SMS TOTVS SERIE T	RIODEJANEIRO	Fabricacao de preparacos farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	MANUFATURA - PARCEIRO	MODALIDADE TRADICIONAL	105	00 - Mensal	ATIVO	RJ	341,155636978792	2015-02-27
2	T00053	HORA SUPORTE	CONSULTORIA TRADICIONAL	RIODEJANEIRO	Fabricacao de preparacos farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	SERVICOS DE IMPLANTACAO	MODALIDADE SERVICOS NAO RECORRENTES	105	00 - Mensal	CANCELADO	RJ	45,3386017130146	1997-11-28
3	99958	CDU FULL TOTVS TRAD	CDU TOTVS SERIE T	JOINVILLE	PESSOA FISICA (SEM CNAE)	SERVICOS	PROVEDOR SERVICOS	Faixa 09 - De 300 M ate 500 M	CROSS - TRADICIONAL	MODALIDADE TRADICIONAL	105	00 - Mensal	GRATUITO	SC	42,0343698218297	2016-04-07
4	T00053	PROGRESS USER 11 CDU	CDU TOTVS SERIE T	RIODEJANEIRO	Fabricacao de preparacos farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	PROGRESS	MODALIDADE TRADICIONAL	105	00 - Mensal	TROCADO	RJ	0,117708006301753	2017-11-22

	clienteid	eventduration	moduloid	productlineid	referencedatestart	slotid	statuslicenca	tcloud	clienteprime
0	TEXKCV00	580.724	6	2	2025-03-19	4133	Desconectado	NaN	NaN
1	TAAHTU00	414787.069	6	2	2025-03-19	4000	Desconectado	NaN	NaN
2	TEXKCV00	4933.511	6	2	2025-03-19	4133	Desconectado	NaN	NaN
3	TEWERU00	414086.474	7	2	2025-03-19	4000	Desconectado	NaN	NaN
4	TFDFHJ00	0.000	524	3	2025-03-19	0	Desconectado	NaN	NaN

Figuras 1 e 2: Amostra de dados .csv enviados pela TOTVS à FIAP para nosso projeto

Logo nos primeiros momentos, já na apresentação, pudemos notar que a TOTVS possui uma vasta base de clientes de diferentes portes e segmentos e a carência de *insights* referentes à eles, que dada a natureza do desafio, essa carência refere-se aos clientes em forma de grupos.

Problemas a serem resolvidos e Proposta de Solução

Com isso em mente, pensamos em algumas perguntas para guiar nosso projeto como: “Quais padrões de comportamento existem?”, “O que influencia NPS, churn e expansão?”, “Qual o impacto financeiro de perdas e retenção?”, “Como agrupar estes clientes?”, “Onde estão os gargalos?”.

Proposta de Solução

Então, como vamos resolver estes problemas da melhor maneira possível?

A primeira etapa de nosso trabalho, se deu, justamente com o desenvolvimento de um modelo de *clusterização* prévio, utilizando KMeans, o qual, ao recebermos o feedback do Profº. Fernando Nemec, percebemos que a direção que estávamos seguindo não era adequada devido ao fato de estarmos utilizando um algoritmo antigo que não era adequado para o nosso problema, como investigações futuras nos mostraram ao notarmos que suas limitações implicam em grupos de tamanhos parecidos, o que com certeza não é o nosso caso, além de sua natureza de “forçar” com que todos os pontos (clientes, neste caso) pertençam à um grupo, que não é o que desejamos.

Buscamos, então, utilizar o algoritmo proposto no *Feedback*, o Gaussian Mixture Model (GMM), porém sua interpretabilidade se mostrou complicada, e, também, tem a natureza de “forçar” clientes em grupos.

Foi então que chegamos ao modelo final, que parece se adequar bem aos dados e nos deu resultados satisfatórios, o Hierarchical Density-Based Spatial Clustering of Applications with Noise (HDBSCAN).

Como nosso objetivo desde o princípio é o de não remover *outliers*, por acreditarmos que eles são, **sim**, pontos relevantes para nossa análise, o HDBSCAN se mostrou a melhor opção, pois o próprio algoritmo é capaz de classificar clientes por densidade em grupos bem definidos e isolar ruídos. E ao mantermos a probabilidade de pertencimento ao *Cluster* em nossa tabela final, podemos analisar com precisão o perfil de um cliente *Ruído*. O detalhamento de como foi este processo se encontra nas documentações do *Jupyter Notebook* (**HDBSCAN_MODELO.ipynb**) em anexo junto deste arquivo.


```
--- Iniciando cross-validation para min_cluster_size=40 ---
Processando grupo: 'P'
  Fold 1/5
    - Treinando HDBSCAN (n=40) em 8268 pontos...
    Número de clusters do treino: 6
      => Silhouette Score Treino: 0.8829
    Número de clusters do teste: 6
      => Silhouette Score Teste: 0.8527
    - Prevendo clusters para 2067 novos pontos...
```

Figura 3: Primeiro *fold* do nosso modelo de *clusterização* utilizando **HDBSCAN**.

Em seguida, pensamos em uma maneira prática de disponibilizarmos as informações de nosso modelo (com os dados já agregados e *clusterizados*) para os diferentes tipos de *stakeholders*, técnicos ou não. E chegamos à conclusão de desenvolvermos uma *API REST*

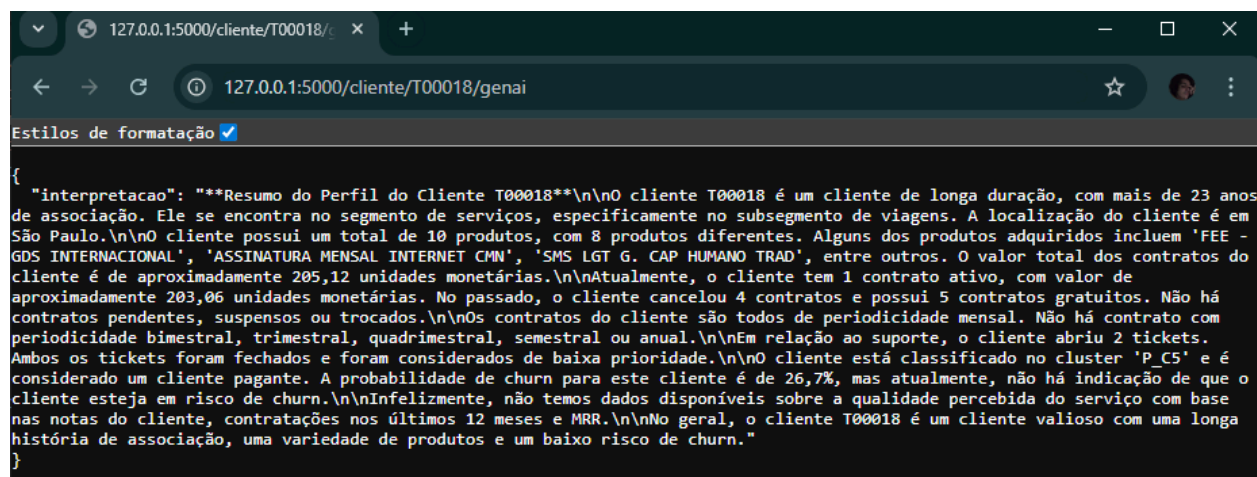
em *Flask* em conjunto com a *API* da *OpenAI* para traduzirmos nossos dados para um formato de linguagem natural, fornecendo informações como:

- Identificação do Cluster ou Cliente (à depender do *Endpoint*);
- Segmentação;
- Métricas (Probabilidade de churn, NPS etc.);
- CLV do Cliente.




```
{
  "AQUISICAO_MEDIA_NOTA_AGILIDADE": null,
  "AQUISICAO_MEDIA_NOTA_CONHECIMENTO": null,
  "AQUISICAO_MEDIA_NOTA_CUSTO": null,
  "AQUISICAO_MEDIA_NOTA_FACILIDADE": null,
  "AQUISICAO_MEDIA_NOTA_FLEXIBILIDADE": null,
  "AQUISICAO_MEDIA_NOTA_NPS": null,
  "CD_CLIENTE": "T00018",
  "CHURN": 0,
  "CLIENTE_DESDE": "Tue, 01 Jan 2002 00:00:00 GMT",
  "CONTRATOS_ATIVO": 1,
  "CONTRATOS_CANCELADO": 4,
  "CONTRATOS_FATURAR": 0,
  "CONTRATOS_GRATUITO": 5,
  "CONTRATOS_PENDENTE": 0,
  "CONTRATOS_SUSPENSO": 0,
  "CONTRATOS_TROCADO": 0,
  "DIAS_DESDE_ULTIMA_ATUALIZACAO_MAX": 31,
  "DIAS_DESDE_ULTIMA_ATUALIZACAO_MEAN": 15.5,
  "DIAS_DESDE_ULTIMA_ATUALIZACAO_MIN": 0,
  "DS_SEGMENTO": "SERVICOS",
  "DS_SUBSEGMENTO": "VIAGENS",
  "EVENTDURATION_S": null,
  "FAT_FAIXA": "Faixa 02 - De 7,5 M ate 15 M",
  "GRUPO_NPS_detrator": null,
  "GRUPO_NPS_passivo": null,
  "GRUPO_NPS_promotor": null,
  "IDADE_ANOS": 23.3073237508556,
  "IDADE_DIAS": 8513,
}
```

Figura 4: Amostra da saída da API para os dados brutos do cliente T00018



```
{
  "interpretacao": "***Resumo do Perfil do Cliente T00018**\n\nO cliente T00018 é um cliente de longa duração, com mais de 23 anos de associação. Ele se encontra no segmento de serviços, especificamente no subsegmento de viagens. A localização do cliente é em São Paulo.\n\nO cliente possui um total de 10 produtos, com 8 produtos diferentes. Alguns dos produtos adquiridos incluem 'FEE - GDS INTERNACIONAL', 'ASSINATURA MENSAL INTERNET CMN', 'SMS LGT G. CAP HUMANO TRAD', entre outros. O valor total dos contratos do cliente é de aproximadamente 205,12 unidades monetárias. Atualmente, o cliente tem 1 contrato ativo, com valor de aproximadamente 203,06 unidades monetárias. No passado, o cliente cancelou 4 contratos e possui 5 contratos gratuitos. Não há contratos pendentes, suspensos ou trocados.\n\nOs contratos do cliente são todos de periodicidade mensal. Não há contrato com periodicidade bimestral, trimestral, quadrimestral, semestral ou anual.\n\nEm relação ao suporte, o cliente abriu 2 tickets. Ambos os tickets foram fechados e foram considerados de baixa prioridade.\n\nO cliente está classificado no cluster 'P_C5' e é considerado um cliente pagante. A probabilidade de churn para este cliente é de 26,7%, mas atualmente, não há indicação de que o cliente esteja em risco de churn.\n\nInfelizmente, não temos dados disponíveis sobre a qualidade percebida do serviço com base nas notas do cliente, contratações nos últimos 12 meses e MRR.\n\nNo geral, o cliente T00018 é um cliente valioso com uma longa história de associação, uma variedade de produtos e um baixo risco de churn."
}
```

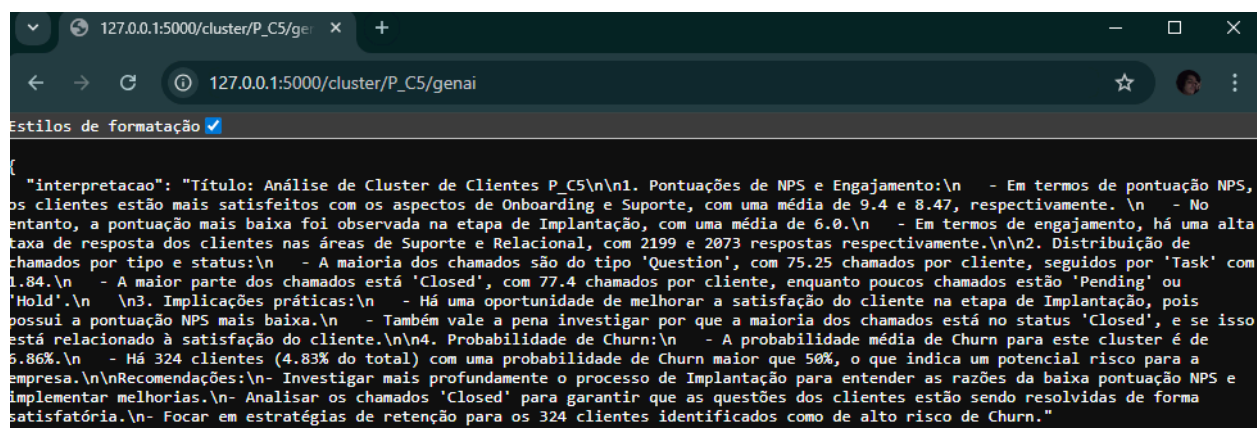
Figura 5: Saída completa da API com os dados brutos do cliente T00018 traduzidos para linguagem natural (sem formatação).



A screenshot of a web browser window displaying a JSON API response. The address bar shows the URL '127.0.0.1:5000/cluster/P_C5'. The page content is a JSON object with various metrics for cluster P_C5, including NPS scores, engagement rates, and churn probabilities. The JSON is displayed in a dark-themed editor with syntax highlighting.

```
{
  "AQUISICAO_MEDIA_NOTA_AGILIDADE": 8.083333333333333,
  "AQUISICAO_MEDIA_NOTA_CONHECIMENTO": 8.5,
  "AQUISICAO_MEDIA_NOTA_CUSTO": 7.333333333333333,
  "AQUISICAO_MEDIA_NOTA_FACILIDADE": 7.166666666666667,
  "AQUISICAO_MEDIA_NOTA_FLEXIBILIDADE": 7.916666666666667,
  "AQUISICAO_MEDIA_NOTA_NPS": 7.89655172413793,
  "Aquisição": 29,
  "CONTRATOS_ATIVO": 7.40211877051626,
  "CONTRATOS_CANCELADO": 3.17845419277828,
  "CONTRATOS_GRATUITO": 2.409280811698,
  "DS_SEGMENTO": "SERVICOS",
  "EVENTDURATION_S": 400.172458794409,
  "FAT_FAIXA": "Sem Informações de Faturamento",
  "IDADE_DIAS": 2621.21963592957,
  "IMPLANTACAO_MEDIA_NOTA_COMUNICACAO": 6.32692307692308,
  "IMPLANTACAO_MEDIA_NOTA_CONHECIMENTO": 7,
  "IMPLANTACAO_MEDIA_NOTA_GESTAO": 6.5,
  "IMPLANTACAO_MEDIA_NOTA_METODOLOGIA": 5.96153846153846,
  "IMPLANTACAO_MEDIA_NOTA_NPS": 6,
  "IMPLANTACAO_MEDIA_NOTA_PRAZOS": 6.11538461538462,
  "IMPLANTACAO_MEDIA_NOTA_QUALIDADE": 6.5,
  "Implantação": 39,
  "Linha de Produto": 850,
  "MRR_12M": 437.232813619812,
  "ONBOARDING_MEDIA_NOTA_AJUDA": 9.32142857142857,
  "ONBOARDING_MEDIA_NOTA_CLAREZA_CANAL": 9.47619047619048,
  "ONBOARDING_MEDIA_NOTA_CLAREZA_GERAL": 9.52380952380952,
  "ONBOARDING_MEDIA_NOTA_EXPECTATIVA": 9.42857142857143,
```

Figura 6: Amostra da saída da API para os dados brutos do cluster P_C5



A screenshot of a web browser window displaying a natural language interpretation of the API data for cluster P_C5. The address bar shows the URL '127.0.0.1:5000/cluster/P_C5/genai'. The page content is a text block providing a detailed analysis of the cluster's performance, including NPS scores, engagement rates, and churn probabilities, translated into natural language.

```
{
  "interpretacao": "Título: Análise de Cluster de Clientes P_C5\n\n1. Pontuações de NPS e Engajamento:\n - Em termos de pontuação NPS, os clientes estão mais satisfeitos com os aspectos de Onboarding e Suporte, com uma média de 9.4 e 8.47, respectivamente. \n - No entanto, a pontuação mais baixa foi observada na etapa de Implantação, com uma média de 6.0.\n - Em termos de engajamento, há uma alta taxa de resposta dos clientes nas áreas de Suporte e Relacional, com 2199 e 2073 respostas respectivamente.\n\n2. Distribuição de chamados por tipo e status:\n - A maioria dos chamados são do tipo 'Question', com 75.25 chamados por cliente, seguidos por 'Task' com 1.84.\n - A maior parte dos chamados está 'Closed', com 77.4 chamados por cliente, enquanto poucos chamados estão 'Pending' ou 'Hold'. \n\n3. Implicações práticas:\n - Há uma oportunidade de melhorar a satisfação do cliente na etapa de Implantação, pois possui a pontuação NPS mais baixa.\n - Também vale a pena investigar por que a maioria dos chamados está no status 'Closed', e se isso está relacionado à satisfação do cliente.\n\n4. Probabilidade de Churn:\n - A probabilidade média de Churn para este cluster é de 5.86%.\n - Há 324 clientes (4.83% do total) com uma probabilidade de Churn maior que 50%, o que indica um potencial risco para a empresa.\n\nRecomendações:\n - Investigar mais profundamente o processo de Implantação para entender as razões da baixa pontuação NPS e implementar melhorias.\n - Analisar os chamados 'Closed' para garantir que as questões dos clientes estão sendo resolvidas de forma satisfatória.\n - Focar em estratégias de retenção para os 324 clientes identificados como de alto risco de Churn."
```

Figura 7: Saída completa da API com os dados brutos do cluster P_C5 traduzidos para linguagem natural (sem formatação).

Mas dados precisam de informação visual, certo? Para isso, desenvolvemos um *Dashboard* Estratégico da Jornada do cliente, com métricas robustas e agregadas por *Cluster*.

Julgamos relevante a apresentação de métricas como NPS, Probabilidade de Churn, Valor de Contratos Ativos e Cancelados de cada grupo e índice de engajamento, que em conjunto com nossa API, a empresa parceira terá uma visão completa de clientes à nível de grupo.





Figura 8: Dashboard da Jornada do Cliente TOTVS, onde pode-se selecionar o *cluster* desejado para visualizar métricas como NPS por etapa, probabilidade de *churn*, total de clientes, valor de contratos ativos e cancelados, além de MRR e valor de contratações dos últimos 12 meses, entre outras informações relevantes.

Para a probabilidade de Churn, desenvolvemos, também, um modelo informativo, não pretendemos nos aprofundar na análise do motivo que faz um cliente abandonar a empresa, o foco de nosso trabalho é a *Clusterização*, portanto, criamos o modelo apenas para gerar uma variável informativa de grande importância para a tomada de decisão baseado em uma regra (detalhada em **Churn_Model.ipynb**) que criamos considerando as quantidades e valores de contratos ativos e cancelados. Nota-se que priorizamos a métrica *Recall*, pois priorizamos a retenção de clientes, afinal, falsos positivos costumam ser menos prejudiciais financeiramente que falsos negativos.



	precision	recall	f1-score	support
0	0.98	0.97	0.97	2902
1	0.70	0.82	0.75	281
accuracy			0.95	3183
macro avg	0.84	0.89	0.86	3183
weighted avg	0.96	0.95	0.95	3183

Figuras 9 e 10: Matriz de Confusão do modelo de Churn e métricas de avaliação.

Impacto Esperado

Com o desenvolvimento deste projeto, esperamos valorizar a jornada do cliente, auxiliando na identificação de gargalos para que a empresa possa, com facilidade, propor soluções para um maior engajamento de clientes e/ou grupos que necessitam de mais atenção. Devido ao fato de termos construído a **variável** de *Churn* e o **modelo** em si da maneira que julgamos correta, o projeto também auxiliará na redução desta métrica tão prejudicial para a saúde da empresa como um todo. Infelizmente não possuímos informações sobre como a empresa lida com casos como este, portanto, mantivemos nossa proposta como um trabalho de **Consultoria**, desenvolvendo ferramentas capazes de auxiliar nas tomadas de decisão.

Benefícios Esperados

Redução de custos com a eliminação de campanhas genéricas e foco em ações com maior retorno de investimento, otimizando o orçamento de marketing e retenção ao direcionar os esforços para grupos mais críticos.

Aumento de Conversões ao identificarmos grupos que “travaram” na etapa de teste, com produtos gratuitos e/ou *free-trial*.

Ganho de Competitividade ao auxiliarmos em uma melhor experiência do usuário, aumentando a eficiência operacional e, consequentemente, os resultados de negócio.

Demonstração prática com nosso modelo de *Clusterização* robusto que separa o “ouro” dos “resíduos”, proporcionando grupos acionáveis e bem definidos. Além de nossa *API* responsável por traduzir os números para textos compreensíveis à qualquer *stakeholder*, mostrando como dados podem ser utilizados para transformar os relacionamentos tanto externamente, como no caso dos clientes, quando internamente, dentre os próprios interessados na Jornada do Cliente dentro da empresa.

Protótipo da Arquitetura

Nossa arquitetura é pensada para lidar com uma carga de dados única, vide os dados que recebemos: *dados_clientes.csv*, *telemetria_*.csv* entre outros.

Embora tenha sido pensada dessa forma, buscamos uma *Stack* capaz de lidar bem com a escalabilidade de nossa *Pipeline*, utilizando **Azure Blob Storage** para armazenamento. E de primeiro momento, realizamos uma ingestão manual em **Python** na camada **Bronze**.

Para os tratamentos e normalizações, **Azure Functions** orientada a eventos no plano de **Consumo** para enviarmos os dados da camada **Bronze** para a camada **Silver**. E para enviar dados da camada **Silver** para a **Gold**, para transformações e agregações, utilizamos a combinação de **Azure Container Apps (ACA)** em conjunto com **Kubernetes Event-Driven Autoscaler (KEDA)** para lidarmos com o grande volume de dados de telemetria de maneira agendada e **Azure Functions**, novamente em plano Consumo e orientada a eventos para lidarmos com o restante dos dados.

Vale ressaltar que todos os códigos que usamos para as **Azure Functions** e para o **ACA** se encontram nos documentos anexos (em formato .ipynb, sendo necessária sua conversão para .py em caso de necessidade de replicabilidade).

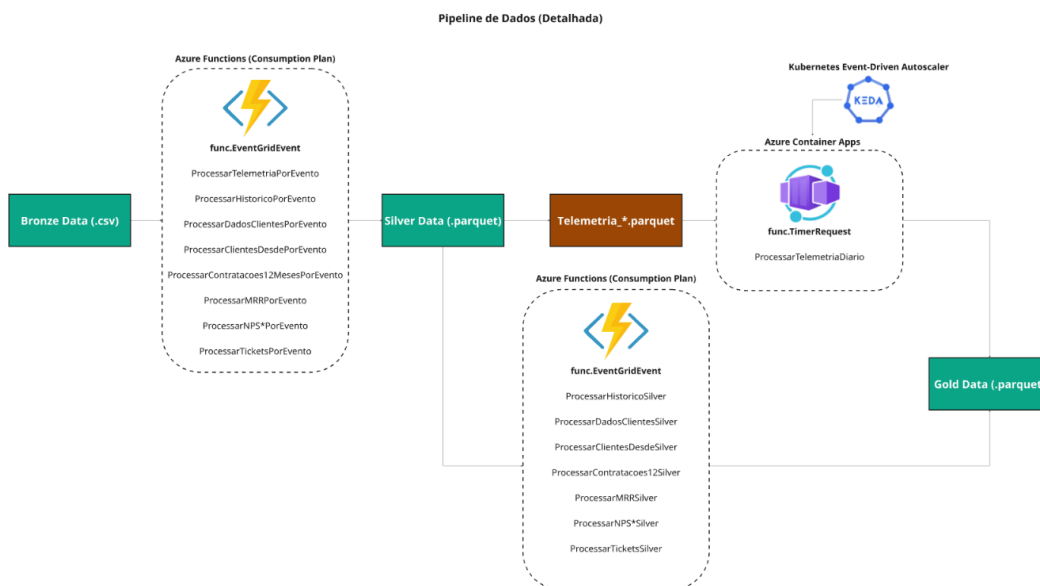


Figura 11: Arquitetura detalhada da *Pipeline* de transformação e agregação de dados.

Em seguida, o modelo desenvolvido no **Google Colab** é salvo em **.pkl** e enviado à camada **Gold** juntamente com o **dataset** completo (com resultados do modelo e agregações) para reaproveitamento, replicabilidade, aprimoramento, consumo da **API** e visualização no **Dashboard**.




Figura 12: Arquitetura Geral de nosso projeto, mostrando todo o fluxo, desde ingestão à disponibilização.

Infelizmente, para o presente trabalho não contaremos com as evidências de implantação em formato de prints para a arquitetura, visto que tivemos problemas com a Azure durante os testes e desenvolvimento, mas, ressaltando novamente, os *scripts* que desenvolvemos estão em anexo.

Detalhando tratamentos e agregações

Abaixo, segue alguns exemplos dos tratamentos realizados da camada Bronze para a camada Silver, como o conjunto de dados é vasto, iremos seguir neste documento, para fins de amostra, com os dados já apresentados anteriormente, sendo necessário o acesso ao **Notebooks Agrupamento1_HDBSCAN.ipynb** e **Agrupamento2_HDBSCAN.ipynb** para acesso completo aos dados. Lembrando que dividimos os notebooks de tratamento e agregações para otimização dos recursos do *Google Colab*.

Dados de telemetria após tratamento das variáveis principais:

	CD_CLIENTE_ORIGINAL	EVENTDURATION_S	moduloid	productlineid	DT_INICIO_EVENTO	slotid	STATUS_LICENCA	tcloud	clienteprime	EVENTDURATION_H	EVENTDURATION_D	CD_CLIENTE
0	TEXKCV00	580.72	6	2	2025-03-19	4133	Desconectado	NaN	NaN	0.16	0.01	TEXKCV
1	TAAHTU00	414787.07	6	2	2025-03-19	4000	Desconectado	NaN	NaN	115.22	4.80	TAAHTU
2	TEXKCV00	4933.51	6	2	2025-03-19	4133	Desconectado	NaN	NaN	1.37	0.06	TEXKCV
3	TEWERU00	414086.47	7	2	2025-03-19	4000	Desconectado	NaN	NaN	115.02	4.79	TEWERU
4	TFDFHJ00	0.00	524	3	2025-03-19	0	Desconectado	NaN	NaN	0.00	0.00	TFDFHJ

Figura 13: Amostra de dados de telemetria após tratamento das variáveis principais

Dados de clientes após tratamento das variáveis principais:

CD_CLIENTE	DS_PROD	DS_LIN_REC	DS_CNAE	DS_SEGMENTO	DS_SUBSEGMENTO	FAT_FAIXA	MARCA_TOTVS	MODAL_COMERC	PERIODICIDADE	SITUACAO_CONTRATO	UF	VL_TOTAL_CONTRATO	DT_ASSINATURA_CONTRATO	
0	99958	SMS FULL TOTVS TRAD	SMS TOTVS SERIE T	PESSOA FISICA (SEM CNAE)	SERVICOS	PROVEDOR SERVICOS	Faixa 09 - De 300 M ate 500 M	CROSS - TRADICIONAL	MODALIDADE TRADICIONAL	00 - Mensal	GRATUITO	SC	1633817.37	2016-04-07
1	T00053	SMS COLAB NEO 2500 DOC	SMS TOTVS SERIE T	Fabricacao de preparacoes farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	MANUFATURA - PARCEIRO	MODALIDADE TRADICIONAL	00 - Mensal	ATIVO	RJ	341.16	2015-02-27
2	T00053	HORA SUPORTE	CONSULTORIA TRADICIONAL	Fabricacao de preparacoes farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	SERVICOS DE IMPLANTACAO	MODALIDADE SERVICOS NAO RECORRENTES	00 - Mensal	CANCELADO	RJ	45.34	1997-11-28
3	99958	CDU FULL TOTVS TRAD	CDU TOTVS SERIE T	PESSOA FISICA (SEM CNAE)	SERVICOS	PROVEDOR SERVICOS	Faixa 09 - De 300 M ate 500 M	CROSS - TRADICIONAL	MODALIDADE TRADICIONAL	00 - Mensal	GRATUITO	SC	42.03	2016-04-07
4	T00053	PROGRESS USER 11 CDU	CDU TOTVS SERIE T	Fabricacao de preparacoes farmaceuticas	MANUFATURA	BENS DURAVEIS	Faixa 05 - De 35 M ate 50 M	PROGRESS	MODALIDADE TRADICIONAL	00 - Mensal	TROCADO	RJ	0.12	2017-11-22

Figura 14: Amostra de dados de clientes após tratamento das variáveis principais

Agora, seguem exemplos das agregações destes conjuntos de dados.

Dados de telemetria após agregação das variáveis:

CD_CLIENTE	EVENTDURATION_S	LICENCA_Conectado	LICENCA_Desconectado	LICENCA_Negado
T00053	229.53	0.00	4400.00	0.00
T00082	301.73	0.00	3101.00	2.00
T00145	493.08	0.00	1016.00	4.00
T00245	91.35	0.00	279.00	24.00
T00255	0.00	0.00	1259.00	0.00

Figura 15: Amostra de dados de telemetria após agregação das variáveis

Dados de cliente após agregação das variáveis:

CD_CLIENTE	QTD_PRODUTOS_DISTINTOS	QTD_TOTAL_PRODUTOS	SOMA_VL_CONTRATOS	LISTA_PRODUTOS	CONTRATOS_ATIVO	CONTRATOS_CANCELADO	CONTRATOS_FATURAR	CONTRATOS_GRATUITO	CONTRATOS_PENDENTE	CONTRATOS_SUSPENSO	CONTRATOS_TROCADO	VALOR_CONTRATOS_ATIVO
0	99069	6	6	8129.77	[TOTVS RHATS PACK 3 VAGAS, CLOUD IAS 36M, SE...	2	2	0	2	0	0	651.60
1	99958	8	8	1634142.18	[SMS FULL TOTVS TRAD, CDU FULL TOTVS TRAD, SMS...	0	0	0	8	0	0	0.00
2	99999	334	356	42.72	[AG VVN01 Min, HORA SUPORTE, BI VVN01 Min, BN VVN...	0	354	0	2	0	0	0.00
3	CARAMU	2	2	85314.57	[ADESAO OT LOG PLA 500 VIAGENS TOTVS OT LOG P...	2	0	0	0	0	0	85314.57
4	T00018	8	10	205.12	[FEE - GDS INTERNACIONAL ASSINATURA MENSAL IN...	1	4	0	5	0	0	203.06

Figura 16: Amostra de dados de cliente após agregação das variáveis

Lembrando que há mais variáveis, mas para fins práticos de visualização, manterei apenas um exemplo amostral, as informações completas se encontram nos notebooks responsáveis pelas agregações.

Tecnologias Utilizadas

Para realizarmos nosso projeto de maneira plena, começamos com o *ClickUp* para gestão e integração de *stakeholders* no projeto. Em seguida, escolhemos nossa *Stack* dentro do Microsoft Azure, para uma solução inteiramente baseada em Nuvem juntamente com o Google Colab, para um maior proveito de máquinas virtuais robustas (principalmente em memória) e armazenamento, ambos já disponibilizados gratuitamente.

Para nossa *API REST*, utilizamos Flask em conjunto com a *OpenAI API* pela simplicidade e agilidade no desenvolvimento de uma *API* simples, mas de grande valor para nós e para a empresa.

Como dito anteriormente, armazenamos os dados disponibilizados pela empresa no Azure Blob Storage (e no Google Colab, para preservarmos recursos, tanto de armazenamento quanto leitura e otimização de tempos de execução das *Azure Functions*).

E finalmente, para as visualizações, construímos nosso *Dashboard* em **PowerBI** para visualização de dados e acompanhamento de pontos críticos envolvendo comportamento e jornada de clientes TOTVS.

Detalhamento da Abordagem para a Segmentação de Clientes

Como dito anteriormente, a aplicação de algoritmos tradicionais como KMeans, embora clássico, impõe uma limitação crucial: a exigência de que cada cliente seja alocado a um segmento. E como optamos por não descartarmos *outliers*, tal característica compromete a integridade de nossas análises e propósitos, pois clientes com perfis de comportamento atípicos eram agrupados de forma arbitrária.




Figura 17: Visualização dos *clusters* do KMeans utilizando PCA com perda de variabilidade de 66%.

Tal processo resultava na formação de segmentos heterogêneos, carentes de coesão e com baixo valor analítico para a tomada de decisão.

Para superar essa limitação, optamos pelo algoritmo **HDBSCAN**, que opera com base na densidade dos dados. O método identifica regiões de alta concentração de comportamento, formando *clusters* robustos, limpos e mais coesos, facilitando nossa análise. O restante dos pontos (clientes) são classificados como “Ruído”, o que identifica clientes atípicos, facilitando a análise individual de cada um.

Ressalta-se que essa classificação “ruidosa” não denota anomalias (ou erros), mas permite identificar clientes com singularidade estatística ou em zonas de transição entre clusters (por este motivo, optamos por preservar a probabilidade de pertencimento ao cluster atribuído).

CD_CLIENTE	rotulos_30_train	probabilidade_30_train	score_outlier_30_train	fold_30_train	rotulos_preditos_30_test	rotulos_40_train	probabilidade_40_train	score_outlier_40_train	fold_40_train	rotulos_preditos_40_test	conjunto
T00018	NaN	NaN	NaN	NaN	P_C10	NaN	NaN	NaN	NaN	P_C5	Teste
T00053	P_Ruido	0.00	0.05	1.00	NaN	P_Ruido	0.00	0.15	1.00	NaN	Treino
T00082	P_C2	1.00	0.00	1.00	NaN	P_Ruido	0.00	0.06	1.00	NaN	Treino
T00145	NaN	NaN	NaN	NaN	P_Ruido	NaN	NaN	NaN	NaN	P_C5	Teste
T00151	P_C10	0.44	0.56	1.00	NaN	P_C5	0.43	0.57	1.00	NaN	Treino

Figura 18: Tabela final do modelo de *clusterização*, com rótulos de treino e teste para os diferentes *min_cluster_size* (30 e 40).

Como resultado, a segmentação obtida apresenta maior fidelidade à dimensão real dos dados, gerando grupos acionáveis, como veremos a seguir.

A visualização dos *clusters* foi realizada com o auxílio do t-SNE, algoritmo de redução de dimensionalidade para um espaço tridimensional, diferentemente do que fizemos antes com o PCA, optamos pelo t-SNE para preservarmos a estrutura local dos dados, já que ele modela as relações de similaridade entre os pontos em alta dimensão e busca recriar essas mesmas relações no espaço 3D, o que nos proporciona uma separação ainda mais objetiva dos *clusters* ao adicionar uma dimensão de profundidade à nossa análise visual, que combinada com nossa análise estatística descritiva, nos permitiu definir perfis de clientes de maneira confiável:




Figura 19: Visualização do t-SNE após redução da dimensionalidade para um plano tridimensional. Nota-se que o gráfico não possui os pontos de ruído. O arquivo completo pode ser encontrado em: HTMLS/tsne_3d_labels_unified_40.html

Descrição dos dados que utilizamos em conjunto com a visualização para definirmos os perfis distintos de cada grupo:

Potulos48	QTD_PRODUTOS_DISTINTOS	CONTRATOS_ATIVO	CONTRATOS_CANCELADO	CONTRATOS_GRATUITO	VALOR_CONTRATOS_ATIVO	VALOR_CONTRATOS_CANCELADO	VALOR_CONTRATOS_GRATUITO	MRR_12M	QTD_CONTRATAÇÕES_12M	VLR_CONTRATAÇÕES_12M	
0	NP_C0	1.09	0.00	0.00	1.11	0.00	0.00	0.01	NaN	1.00	0.00
1	NP_C1	11.41	0.00	1.09	10.35	0.00	305.70	0.05	NaN	NaN	NaN
2	NP_Ruido	17.55	0.00	11.71	9.18	0.00	10327.98	760.20	801.58	1.06	4890.70
3	P_C0	19.92	17.33	9.10	6.50	39973.62	13918.51	3022.83	764.90	2.11	7528.05
4	P_C1	11.40	10.44	3.84	2.71	14452.14	2587.73	0.99	570.03	1.32	4539.78
5	P_C2	15.27	12.31	3.32	2.35	19262.21	3007.81	0.14	692.80	1.71	2275.96
6	P_C3	9.82	11.02	2.35	1.11	15557.61	2135.56	0.01	255.32	1.29	2971.37
7	P_C4	12.59	8.08	4.04	2.97	5335.84	1164.20	0.12	171.57	1.39	562.02
8	P_C5	9.12	7.40	3.18	2.41	11145.65	3416.90	0.13	437.23	1.40	2879.39
9	P_Ruido	24.48	21.70	9.62	5.25	103886.10	55602.09	20639.35	1029.64	2.36	20939.42

Figura 20: Tabela gerada através de **.describe()**, após agregação final para definirmos perfis de *clusters*, tal tabela pode ser encontrada em **HDBSCAN_MODELO.ipynb**.

Vale ressaltar que dividimos os clientes em dois grupos: Pagantes e Não Pagantes, seguimos com uma regra baseada na quantidade de contratos por tipo (detalhes no *Jupyter Notebook HDBSCAN_MODELO.ipynb*).

Não Pagantes

- **Cluster NP_C0 (Clientes de Entrada e Gratuitos)**
 - a. Este cluster tem a menor base de produtos, com uma média de apenas 1.09 de produtos distintos;
 - b. Não possuem contratos ativos;
 - c. A base de clientes é composta principalmente por contratos gratuitos;
 - d. O MRR dos últimos 12 meses é nulo, e as contratações recentes, sem valor;
 - e. Possuem uma idade média de cerca de 2 anos
 - f. O que os diferencia: O diferencial absoluto deste grupo é a sua total dependência de produtos gratuitos. São clientes que ainda não converteram para planos pagos e não geram receita direta para a empresa.
- **Cluster NP_C1 (Veteranos de Produtos Gratuitos)**
 - g. Possuem uma quantidade considerável de produtos distintos (média de 11.41), mas a grande maioria em contratos gratuitos (média de 10.35).
 - h. Também não possuem contratos ativos, devido ao fato de serem “Não-Pagantes”, e possuem um pequeno histórico de cancelamento, com valor médio de R\$305.70.
 - i. São clientes muito antigos, com uma idade média de cerca de 11 anos.

- j. O que os diferencia: O que torna este grupo único é a combinação de uma longa permanência como cliente com a ausência total de receita recorrente. São usuários leais aos produtos gratuitos, mas que nunca deram o passo para se tornarem clientes pagantes.
- **Cluster NP_Ruido (Clientes com Grande Histórico de Cancelamento)**
 - k. Altíssimo número de contratos cancelados (média de 11.7), superando os contratos gratuitos, também altos (9.1).
 - l. O valor dos contratos cancelados é expressivo, em média R\$10.327,98, indicando que já foram clientes de valor no passado.
 - m. Possuem um MRR médio de R\$801,00, que provavelmente é residual ou serviços pontuais que não constam na base de dados, devido a ausência de contratos ativos.
 - n. O que os diferencia: O diferencial deste grupo é um dos mais claros, o histórico massivo de cancelamentos. Este cluster representa clientes que geraram uma perda de receita significativa para a empresa. A moderada quantidade de tickets abertos (média de 65) pode ser um reflexo de problemas que levaram aos cancelamentos. Mas, é preciso cuidado ao analisar esse cluster, por se tratar de clientes classificados como ruídos, o ideal é analisar cada caso individualmente.

Pagantes

- **Cluster P_C0 (Clientes de Alto Valor e Alta Complexidade)**
 - a. É um dos grupos de maior valor, com uma média de R\$ 39.973,62 em contratos ativos.
 - b. Possuem um portfólio de produtos grande e diversificado (média de 19.92 produtos).
 - c. Apresenta boa atividade de contratações nos últimos 12 meses, tanto em quantidade (2.11) quanto em valor (R\$ 7.528,05).
 - d. Também possuem um volume relevante de contratos cancelados (R\$ 13.918,51), o que é esperado para uma base dinâmica.
 - e. Possuem, em média 182 tickets abertos. Indicando alta demanda por suporte, possivelmente devido à complexidade dos produtos.
 - f. O que os diferencia: O grupo se destaca pelo altíssimo valor gerado, combinado com uma demanda extremamente alta por suporte. São clientes valiosos, mas que exigem atenção e recursos além do normal.
- **Cluster P_C1 (Novos Clientes de Valor Moderado)**
 - a. Representam um grupo de clientes com valor de contratos ativos moderado (média de R\$14.452,14).
 - b. São clientes relativamente novos, de cerca de 3.7 anos, em média.
 - c. Apresentam um bom volume de contratações recentes (em média, R\$4.539,78).
 - d. Têm, também, um altíssimo número de tickets abertos (com média de 222).

- e. O que os diferencia: Potencial de crescimento com alta demanda. O diferencial é a combinação de serem clientes mais jovens com valor moderado e uma necessidade de suporte muito elevada.

- **Cluster P_C2 (Clientes Estáveis e Satisfeitos)**

- f. Possuem um valor de contratos ativos sólido, com média de R\$19.262,21 e um MRR médio de R\$692,80.
- g. Apresentam baixa quantidade de contratos cancelados, indicando estabilidade.
- h. São clientes com idade de aproximadamente 7 anos.
- i. Apresentam um volume de tickets baixo para moderado (110, aproximadamente).
- j. As notas de suporte são altas, para os clientes engajados. Com destaque para notas relacionadas a “Conhecimento do Agente”: 9.38 e “Solução Apresentada”: 9.41.
- k. O que os diferencia: Este cluster se destaca pela estabilidade, bom valor de contratos e alta satisfação com o suporte. São nossa “base sólida” de clientes.
- l.

- **Cluster P_C3 (Clientes de Baixo Custo e Baixo Engajamento)**

- a. Apresentam um valor de contrato ativo com média de R\$15.557,61, e o MRR é um dos menores dentre os grupos pagantes: R\$255,32, em média.
- b. Possuem uma boa quantidade de produtos distintos entre os pagantes (média de 9.82 por cliente).
- c. Baixa atividade de novas contratações nos últimos 12 meses (1.29), mas com um bom valor (R\$2.971,37).
- d. O que os diferencia: Baixo MRR e a baixa complexidade de produtos. Aparentam ser clientes que provavelmente utilizam soluções mais básicas ou de entrada, além de possuírem um baixo engajamento.

- **Cluster P_C4 (Clientes de Pequeno Porte e Cautelosos)**

- e. Este é o grupo com menor valor em contratos ativos entre os pagantes, com média de R\$5.335,84 e o menor MRR, de R\$171,57.
- f. As contratações nos últimos 12 meses também não representam números significativos: R\$562,02
- g. A quantidade de tickets abertos também não é muito alta: 89, em média.
- h. O que os diferencia: Grupo formado por clientes que consomem pouco, com um ticket médio baixo e pouca receita gerada.

- **Cluster P_C5 (Clientes Padrão e Diversificados)**

- i. Grupo que representa o “cliente médio”, é o maior grupo, com mais de 6000 clientes.
- j. Apresentam valor de contrato ativo de média R\$11.145,65. MRR de R\$437,23 e idade de aproximadamente 7 anos.

- k. Possuem, também, uma base de produtos relativamente boa, com média de 9.12.
 - l. Apresentam a segunda menor média de tickets abertos dentre todos os grupos, sendo 79 a média dos clientes padrões.
 - m. As notas apresentam altos e baixos, como uma média de 5.96 para Metodologia de Implantação, mas 9.52 para Clareza Geral do Onboarding.
 - n. O que os diferencia: São os clientes de comportamento equilibrado, o coração dos clientes da TOTVS. São estáveis, geram receita consistente e demandam pouco suporte, o que os torna clientes de alta eficácia.
- **Cluster P_Ruido (Clientes de Risco Elevado)**
 - o. Por serem um grande grupo classificados como “ruídos”, são clientes que apresentam comportamentos distintos entre si e entre os outros grupos. Além de ser nosso segundo maior grupo, com cerca de 3000 clientes.
 - p. É de longe o grupo de maior valor monetário, com média de R\$103.886,10 em contratos ativos, maior MRR (R\$1.029,64) e maior volume de novas contratações (R\$20.939,42).
 - q. Possuem o maior e mais complexo portfólio de produtos (média de 24.48).
 - r. Contudo, também apresentam o maior valor em contratos cancelados, média de R\$55.602,09, indicando um altíssimo risco de churn e perda de receita.
 - s. O que os diferencia: É nosso grupo ruidoso entre os pagantes, é preciso cuidado ao analisar, pois as métricas podem ser enganosas, sendo necessário uma análise mais granular, a nível de cliente. Mas, de primeiro momento, aparentam ser nosso grupo mais rentável e de maior risco. São nossos clientes “VIP” do grupo de Pagantes.




Figura 21: Gráfico de quantidade de contratos ativos por cluster




Figura 22: Gráfico de valor de contratos ativos por cluster




Figura 23: Gráfico de quantidade de contratos cancelados por cluster




Figura 24: Gráfico de valor de contratos cancelados por cluster




Figura 25: Gráfico de valor de MRR dos últimos 12 meses por cluster




Figura 26: Gráfico de quantidade de contratações nos últimos 12 meses por cluster




Figura 27: Gráfico de valor de contratações nos últimos 12 meses por cluster

Comparação Estatística

Antes de mais nada, é importante dizer que os códigos, resultados encontrados e gráficos desta parte estão em ***ComparacaoEstatisticaSimples.ipynb***.

--- Tabela Comparativa (Apenas Pagantes) ---

rotulos40	Média Geral (Pagantes)	P_C0	P_C1	P_C2	P_C3	P_C4	P_C5
Qtd. Produtos Distintos	9.39	19.92	11.40	15.27	9.82	12.59	9.12
Valor Contratos Ativos (R\$)	11,583.45	39,973.62	14,452.14	19,262.21	15,557.61	5,335.84	11,145.65
Valor Contratos Cancelados (R\$)	3,481.02	13,918.51	2,587.73	3,007.81	2,135.56	1,164.20	3,416.90
Soma Total de Contratos (R\$)	15,119.57	57,266.42	17,042.91	23,177.89	17,693.18	6,687.81	14,568.18
MRR Últimos 12 Meses (R\$)	442.08	764.90	570.03	692.80	255.32	171.57	437.23
Valor Novas Contratações (12M, R\$)	2,986.77	7,528.05	4,539.78	2,275.96	2,971.37	562.02	2,879.39
Idade do Cliente (Anos)	7.16	10.72	3.70	6.82	6.88	7.40	7.18
Qtd. Contratos Ativos	7.65	17.33	10.44	12.31	11.02	8.08	7.40
Qtd. Contratos Cancelados	3.25	9.10	3.64	3.32	2.35	4.04	3.18
Tempo de Uso de Produtos TOTVS	474.35	2,030.94	952.19	246.16	1,169.57	193.66	400.17
Qtd. Tickets Abertos	83.60	182.78	221.83	109.82	121.50	88.89	79.08

Figura 28: Tabela da média geral somente dos clientes pagantes (sem ruídos).

Devido a limitação de tempo, realizamos uma validação estatística simples utilizando o Teste de *Kruskal-Wallis* devido à natureza dos dados. A tabela acima foi gerada em agregações pela média para que o teste pudesse ser aplicado.

Em seguida, aplicamos o teste somente para as variáveis acima, visto que, em nossa visão, são nossos principais indicadores de interesse (que também estão em nosso dashboard).

O Teste de *Kruskal-Wallis* é uma forma robusta de validarmos nossos segmentos, visto que para todas estas variáveis, foi encontrado um *p-valor* menor que 0.05, rejeitando H_0 para, pelo menos, dois grupos distintos.

```
--- Teste de Kruskal-Wallis ---
Variável: Qtd. Produtos Distintos
Estatística H: 158.3545
p-valor: 2.2192882891030893e-32
Variável: Valor Contratos Ativos (R$)
Estatística H: 147.3533
p-valor: 4.884297978155673e-30
Variável: Valor Contratos Cancelados (R$)
Estatística H: 75.9857
p-valor: 5.792350024012891e-15
Variável: Soma Total de Contratos (R$)
Estatística H: 184.3789
p-valor: 6.20967049228914e-38
Variável: MRR Últimos 12 Meses (R$)
Estatística H: 92.0147
p-valor: 2.5348134689094665e-18
Variável: Valor Novas Contratações (12M, R$)
Estatística H: 43.3635
p-valor: 3.118385602932863e-08
Variável: Idade do Cliente (Anos)
Estatística H: 120.4845
p-valor: 2.478039459964493e-24
Variável: Qtd. Contratos Ativos
Estatística H: 109.2747
p-valor: 5.831180298650544e-22
Variável: Qtd. Contratos Cancelados
Estatística H: 71.8022
p-valor: 4.319070343020747e-14
Variável: Tempo de Uso de Produtos TOTVS
Estatística H: 45.0987
p-valor: 1.3853453337076057e-08
Variável: Qtd. Tickets Abertos
Estatística H: 40.5678
p-valor: 1.1471113649453895e-07
```

Figura 29: Resultados do Teste de Kruskal-Wallis

Em seguida, foi realizada comparações Par a Par com o Teste de *Mann-Whitney U* e corrigindo o *p*-valor com a Correção de *Bonferroni* para que pudéssemos ter uma visão mais clara de quais segmentos possuem diferenças significativas para as variáveis de interesse. Por exemplo:

```
=====
Analisando variável: Valor Contratos Ativos (R$)
=====
```

Par de Clusters	p-valor Original	p-valor Corrigido	Significativo?
P_C5 vs P_C0	0.0000	0.0000	Sim
P_C5 vs P_C2	0.0000	0.0000	Sim
P_C5 vs P_C1	0.0573	0.8600	Não
P_C5 vs P_C3	0.0000	0.0000	Sim
P_C5 vs P_C4	0.7592	1.0000	Não
P_C0 vs P_C2	0.0004	0.0061	Sim
P_C0 vs P_C1	0.0000	0.0000	Sim
P_C0 vs P_C3	0.0016	0.0233	Sim
P_C0 vs P_C4	0.0000	0.0000	Sim
P_C2 vs P_C1	0.0006	0.0090	Sim
P_C2 vs P_C3	0.6557	1.0000	Não
P_C2 vs P_C4	0.0000	0.0000	Sim
P_C1 vs P_C3	0.0006	0.0090	Sim
P_C1 vs P_C4	0.4184	1.0000	Não
P_C3 vs P_C4	0.0000	0.0000	Sim

Figura 30: Resultados do Teste de Mann-Whitney U para Valor de Contratos Ativos.




Figura 31: Boxplot da Distribuição dos Valores de Contratos Ativos por Cluster Pagante.

```

=====
Analisando variável: Idade do Cliente (Anos)
=====

```

Par de Clusters	p-valor Original	p-valor Corrigido	Significativo?
P_C5 vs P_C0	0.0000	0.0000	Sim
P_C5 vs P_C2	0.9178	1.0000	Não
P_C5 vs P_C1	0.0000	0.0000	Sim
P_C5 vs P_C3	0.2454	1.0000	Não
P_C5 vs P_C4	0.0783	1.0000	Não
P_C0 vs P_C2	0.0001	0.0012	Sim
P_C0 vs P_C1	0.0000	0.0000	Sim
P_C0 vs P_C3	0.0150	0.2246	Não
P_C0 vs P_C4	0.0130	0.1956	Não
P_C2 vs P_C1	0.0000	0.0000	Sim
P_C2 vs P_C3	0.1350	1.0000	Não
P_C2 vs P_C4	0.0692	1.0000	Não
P_C1 vs P_C3	0.0000	0.0000	Sim
P_C1 vs P_C4	0.0000	0.0000	Sim
P_C3 vs P_C4	0.7210	1.0000	Não

Figura 32: Resultados do Teste de Mann-Whitney U para Idade do Cliente em Anos.




Figura 33: Boxplot da Distribuição da Idade do Cliente em Anos.

Análise de CLV

Nosso objetivo com esta análise simples de *Customer Life-Time Value* é entender como os grupos mais bem-definidos impactam a saúde financeira da empresa parceira. Nota-se, nosso objetivo, aqui, não é entender o motivo do *churn*, mas sim, seu impacto.

Por termos utilizado o **HDBSCAN** como nosso modelo de *clusterização*, tiramos os clientes classificados como ruídos, tanto pagantes, como não pagantes, pois como citado anteriormente, focar nos grupos mais bem-definidos pode ser mais vantajoso do ponto de vista estratégico.

Com esses pontos em mente, nossa avaliação revela com mais precisão quais são os *clusters* que formam o núcleo do negócio e onde as perdas estão mais concentradas.

Análise 1: O impacto do Churn nos Segmentos Principais

Mesmo sem os *clusters* de ruído, a tendência principal é a de que: clientes que cancelaram seus contratos possuem, em média, um valor histórico mais de duas vezes superior ao dos clientes que permanecem ativos (R\$31.076,84 contra R\$13.666,67).

Essa descoberta nos mostra que a empresa está perdendo clientes de alto valor. A perda total de valor histórico, focando apenas nestes *clusters* mais bem definidos, foi de mais de **R\$16 milhões**.




Figura 34: Gráfico da Análise 1 (sem ruídos) para comparar os clientes Churn e Ativos.

Análise 2: O Protagonista dos Clusters Ativos

Com os ruídos removidos, o cluster P_C5 é o pilar central da base de clientes ativos. Ele não só concentra a esmagadora maioria dos clientes (6.241), como também gera a maior parte da receita recorrente total, somando mais de **R\$71 milhões**, o que é esperado, devido ao fato de mais da metade de nossa base de dados se encaixar neste grupo.

Por outro lado, o cluster P_C0, embora pequeno em número de clientes, destaca-se por ter a maior receita recorrente média, por cliente ativo, de mais de **R\$42 mil** em contratos ativos, consolidando-se como um segmento “**premium**” em nossa visão.




Figura 35: Gráfico de barras para visualização do *cluster* P_C5, em comparação com os outros.




Figura 36: Gráfico de barras para visualizar a receita recorrente média do *cluster* P_C0 em comparação com os demais.

Análise 3: Onde a Perda de Valor Realmente Acontece

A análise de *churn* por cluster agora aponta diretamente para o P_C5 como a principal fonte de perda de valor, o que, novamente, é explicado devido à alta concentração de clientes **neste cluster**. Este segmento foi responsável por mais de **R\$15 milhões**, em valor histórico, perdido, proveniente dos 461 clientes que cancelaram.

O *cluster* P_C0 também merece atenção: apesar de ter perdido apenas 9 clientes, o prejuízo foi de mais de **R\$771 mil**, evidenciando o alto custo de perder um cliente deste segmento *premium*.




Figura 37: Gráfico de barras para visualizar o valor histórico perdido dos *clusters* P_C0 e P_C5 em comparação com os demais.

Estratégia de Retenção

A análise, sem ruído, oferece um mapa claro para a ação. A estratégia de retenção deve ter dois focos principais:

- 1. Contenção no P_C5:** Dado o grande volume de clientes, é necessário esforço de retenção em massa, pois mesmo que de baixo custo individual, podem ter o maior impacto no *churn* geral da empresa, prejudicando gravemente a saúde financeira. Entender os motivos de cancelamento do **cliente médio** é crucial para o funcionamento geral da TOTVS.
- 2. Proteção ao P_C0:** Para o *cluster premium*, uma abordagem de alta personalização é essencial. A perda de cada um destes clientes é **extremamente** prejudicial e a prevenção proativa do *churn* deve ser prioridade.